面向医疗大模型的指南驱动动态临床推理评测框架

1. Background and Motivation

现有医疗多模态大模型（Medical MLLMs）评测，大多聚焦于最终答案的正确性，例如疾病分类、诊断问答、报告生成等。近期一些工作开始引入 Chain-of-Thought（CoT）评测，希望通过分析中间推理步骤来评价模型的“思维过程”。然而，这类评测仍然存在明显局限。

首先，**自由形式的 CoT 并不等同于临床思维过程**。在真实医疗场景中，医生的诊断推理并非对图像或病例进行任意的逐步描述，而往往是在临床指南、诊疗规范、风险分层标准和检查适应证的约束下进行。也就是说，真实临床推理具有较强的**路径性、规范性与决策性**，而不仅仅是语言层面的“解释链”。

其次，**临床推理本质上是动态的序列过程，而不是静态的一次性回答**。医生通常在信息不完整的情况下，先根据主诉、既往史和初步检查建立鉴别诊断，再决定下一步检查；随着新证据不断出现，诊断假设被更新、确认或否定，最终形成诊断与管理决策。因此，真实临床推理是一个“信息获取—证据整合—诊断更新—下一步决策”的闭环过程，而不是在看到全部信息后对答案进行事后解释。

基于以上观察，我们认为，现有 CoT benchmark 虽然能够评测模型的文本化推理表述能力，但**并未真正触及医疗领域的临床思维本质**。因此，有必要构建一个新的评测框架，将医疗推理从“静态自由文本解释”推进到“指南约束下的动态临床决策过程评测”。

2. Research Objective

本项目旨在提出一个新的医疗推理 benchmark，用于评测医疗大模型是否能够在**不完整信息条件下**，沿着**符合临床指南的合理路径**，动态地选择检查、整合证据、更新诊断并做出安全有效的管理决策。

具体目标包括：

1. 构建一个 **Guideline-Grounded Dynamic Clinical Reasoning Benchmark**，将临床推理建模为序列决策过程，而非单轮问答；
2. 建立**指南路径标注体系**，将临床指南中的节点、分支条件、必经步骤、可替代步骤与禁忌动作结构化表示；
3. 提出一组新的**过程级评测指标**，覆盖指南符合性、动态更新能力、诊断效率和临床安全性；
4. 系统比较不同类型模型在“全信息静态设置”和“分步动态设置”下的表现差异，从而揭示现有 Medical MLLMs 的真实临床推理能力边界。

3. Core Hypothesis

本项目基于以下两个核心假设展开：

Hypothesis 1

自由形式 CoT 与真实临床思维并不等价。
模型即使能够生成看似合理的中间步骤，也未必遵循临床指南或符合实际诊疗路径。

Hypothesis 2

医疗推理能力不能仅通过全信息下的最终答案正确率来衡量。
一个模型即使在看到全部检查结果后能够给出正确诊断，也不代表它具有在不完整信息下合理规划检查、动态更新判断和安全决策的能力。

---

4. Proposed Framework

我们提出一个两层评测框架：

4.1 Guideline-Grounded Reasoning Evaluation

这一层关注模型是否能够将当前病例状态映射到**正确的指南节点与路径分支**，包括：

- 当前属于哪个诊疗阶段
- 应优先考虑哪些风险点
- 下一步推荐进行什么检查或操作
- 该动作是否符合临床指南

这一层解决的问题是：
模型是否“按指南在走”。

4.2 Dynamic Clinical Workup Evaluation

这一层关注模型能否在多轮交互中进行**动态信息获取与诊断更新**，包括：

- 在信息不完整时是否能提出合理的下一步检查
- 获得新证据后是否会更新鉴别诊断
- 是否存在不必要检查、漏检、错误顺序或危险延误
- 最终是否能以合理成本到达正确诊断与处置

这一层解决的问题是：
模型是否真正具备“临床过程推理能力”。

---

5. Benchmark Unit: From QA Sample to Clinical Episode

与传统的单轮 QA 样本不同，本项目将每个评测单元定义为一个 **clinical episode**。

每个 episode 包含以下几个组成部分：

5.1 Initial State

模型在起始阶段仅能获得部分临床信息，例如：

- 人口学信息（年龄、性别）

- 主诉
- 现病史摘要
- 既往史中的关键信息
- 初始生命体征
- 初始图像或基础检查结果

注意：在主评测协议中，不会一次性提供全部信息。

5.2 Action Space

模型在每一轮可以从结构化动作空间中进行选择，例如：

- 询问某项补充病史
- 进行体格检查
- 开具实验室检查
- 开具影像学检查
- 给出当前鉴别诊断
- 风险分层
- 给出转诊/住院/治疗建议
- 终止诊断并输出最终结论

5.3 Environment Feedback

模型执行某个动作后，环境返回对应的观察结果，例如：

- 血液检查结果
- 影像报告或新图像
- 体格检查结果
- 补充病史信息
- 病理或高级检查结果

从而形成一个序列状态转移过程：

[s_{t+1} = (s_t, a_t, o_t)]

5.4 Guideline Graph

每类疾病或任务都对应一个**临床指南路径图**，其中：

- 节点表示临床评估、风险分层、检查选择、诊断确认或处置环节；
- 边表示在特定条件下允许的下一步动作；
- 分支条件对应检查结果、症状或风险因素；
- 部分节点是 mandatory steps；
- 部分节点是 optional steps；
- 部分动作是 forbidden actions。

这样，模型推理过程可以表示为在指南图上的一条轨迹，而不只是文字解释。

5.5 Acceptable Path Set

临床推理通常不是唯一的，因此每个病例不应只标注一条唯一 gold path，而应标注一个**可接受路径集合**，允许：

- 合理的步骤顺序差异
- 医疗资源差异下的替代检查
- 不同但合规的诊疗方案

这样能够避免僵化的一对一 CoT 匹配。

---

6. Annotation Scheme

本项目建议构建以下五类标注：

6.1 Guideline Node Annotation

标注病例在每一阶段可能对应的指南节点与关键临床阶段。

6.2 Branch Condition Annotation

标注不同路径分支的触发条件，例如某影像学征象、某实验室异常值、某红旗症状等。

6.3 Evidence-Grounding Annotation

标注每一步推理所依赖的证据来源，包括病史、图像、实验室结果、体征或指南条款。

6.4 Dynamic Belief Annotation

标注在每个阶段专家认为合理的鉴别诊断排序或后验判断分布，用于评测模型是否真正进行了诊断更新。

6.5 Safety Annotation

标注高风险错误，包括：

- 漏掉红旗症状
- 延误关键检查
- 做出禁忌操作
- 过早终止诊断
- 不必要的侵入性检查

---

7. Evaluation Protocol

7.1 Main Protocol: Sequential Information Revelation

主评测采用**分步揭示（sequential reveal）**方式。
模型在每一轮只能看到当前阶段本应可见的信息，必须先决定下一步操作，之后才能获得新结果。

这是本 benchmark 的核心协议，因为它能够真实评测模型的：

- 检查规划能力
- 动态更新能力
- 路径合理性
- 临床安全性

7.2 Auxiliary Protocol: Full-Information Setting

作为对照，保留一个**一次性提供全部信息**的辅助设置。
其目的不是评测真实临床过程，而是测量模型在信息充分条件下的最终诊断能力上界。

通过比较 full-information 与 sequential-interaction 的性能差异，可以揭示：

- 模型是否“知道最终怎么诊断”
- 但“不知道在真实流程中应该先做什么”

---

8. Evaluation Tasks

本 benchmark 可设计四类任务：

Task 1: Guideline Mapping

给定当前病例状态，预测当前应进入的指南节点或分支。

Task 2: Next-best Action Selection

给定当前可见信息，选择下一步最合理的检查或管理动作。

Task 3: Sequential Differential Diagnosis Update

在新证据出现后，更新鉴别诊断排序与置信度。

Task 4: Final Diagnosis and Management

在 episode 结束时，输出最终诊断、严重程度、风险分层和管理建议。

---

9. Evaluation Metrics

本项目建议从五个维度进行评测。

9.1 Outcome Metrics

衡量最终结果是否正确，包括：

- Final diagnosis accuracy
- Severity / grading accuracy

- Management / triage accuracy

9.2 Guideline-Conformity Metrics

衡量模型过程是否符合指南，包括：

Mandatory Step Recall

是否覆盖了应执行的关键步骤。

Legal Transition Rate

轨迹中的状态转移是否属于指南允许的边。

Branch Appropriateness

在当前证据下，是否选择了正确分支。

Forbidden Action Penalty

是否出现禁忌动作或明显不推荐动作。

9.3 Dynamic Reasoning Metrics

衡量模型是否进行了真实的动态推理，包括：

Belief Update Alignment

模型的鉴别诊断排序与专家排序的一致性。

Revision Capability

在反证出现后，模型是否能够修正原有错误假设。

Evidence Utilization Score

模型是否真正利用了新增证据，而不是重复旧结论。

9.4 Efficiency Metrics

衡量模型是否高效，包括：

- Time-to-correct-diagnosis
- Number of steps
- Total workup cost
- Invasiveness burden
- Over-testing rate

9.5 Safety Metrics

衡量模型是否安全，包括：

- Red-flag miss rate
- Critical delay rate
- Contraindicated action rate
- Premature closure rate

---

10. Data Construction Plan

本 benchmark 的数据构建可以分为三步。

Phase 1: Case Collection

收集具有明确临床路径的病例，可优先从以下场景入手：

- 眼科
- 放射科
- 神经科
- 急诊分诊
- 肿瘤筛查/随访

优先选择那些**已有较清晰诊疗指南**且**检查流程具有代表性**的任务。

Phase 2: Guideline Structuring

将临床指南或专家共识转化为可计算的结构化路径图，包括：

- 节点
- 条件分支
- 必做/可选/禁忌动作
- 终止条件

Phase 3: Episode Annotation

由临床专家为每个病例标注：

- 初始可见信息
- 各轮可返回的检查结果
- 合理动作集合
- 可接受路径集合
- 最终标准诊断与管理方案
- 风险性错误标签

---

11. Expected Contributions

本项目预期贡献如下：

Contribution 1

指出现有自由形式 CoT benchmark 无法充分代表真实临床思维，因为临床推理受到指南约束且具有动态决策属性。

Contribution 2

提出一个新的 benchmark，将医疗推理建模为**指南驱动的序列决策问题**，而不是静态解释任务。

Contribution 3

提出一套新的过程级评测指标，能够系统衡量模型的指南遵循性、动态更新能力、诊断效率和临床安全性。

Contribution 4

揭示现有 Medical MLLMs 在“拿到全部信息后做结论”和“在不完整信息下动态决策”之间的能力鸿沟。

---

12. Potential Research Questions

基于该 benchmark，可以进一步回答以下研究问题：

1. Medical MLLMs 在 full-information 与 sequential setting 下的差距有多大？
2. 通用大模型和医学专用模型，谁更擅长动态临床推理？
3. 显式 CoT 是否真的能够帮助 sequential clinical reasoning？
4. 哪类错误最常见：漏掉红旗、过检、路径跳跃，还是过早定论？
5. 模型是否能在反证出现后修正错误判断，还是容易陷入 confirmation bias？

---

13. Conclusion

本 proposal 旨在推动医疗大模型评测从“静态答案与文本 CoT 对齐”走向“指南约束的动态临床推理评测”。与现有 benchmark 相比，该框架更贴近真实诊疗流程，能够更忠实地刻画模型在不完整信息条件下的检查规划、证据整合、诊断更新和安全决策能力，从而为医疗 AI 的可信评测提供新的研究方向。